TP INTEGRADOR | IFTS N.º 18

BugTriage AI



Clasificación asistida de reportes de errores con IA preentrenada

Gabriela Coronel • Seminario de Actualización 2026

Demo pública: huggingface.co/spaces/lagabyok/bugtriage-ai

El triage de bugs consume tiempo

Los reportes llegan con distintos niveles de detalle y claridad.

- Leer y categorizar cada reporte de forma manual puede demorar la derivación.
- La redacción puede ser informal, ambigua o mezclar más de un problema.
- Objetivo: proponer una categoría inicial, sin reemplazar el criterio humano.

¿Qué hace BugTriage AI?

Una aplicación web sencilla para apoyar la primera clasificación.





- Entrada: descripción textual de un error.
- Salida: Funcional, UI/UX, Autenticación, Datos o Accesibilidad.
- Muestra score y categorías alternativas para facilitar la revisión.
- No reproduce el bug, no determina la severidad real ni crea tickets automáticamente.

De un texto a una sugerencia

La app usa inferencia; no entrena un modelo propio.

- Gradio construye la interfaz web.
- Transformers pipeline ejecuta zero-shot classification.
- facebook/bart-large-mnli compara el reporte con etiquetas candidatas.
- Hugging Face Spaces aloja la aplicación publicada.
- La persona usuaria revisa la salida antes de actuar.



Comparé dos modelos con los mismos 12 casos

Resultados exploratorios registrados en el notebook.

- BART-large-MNLI: 6/12 correctos · 50,00 % · 0,90 s/caso.
- mDeBERTa multilingüe NLI: 2/12 correctos · 16,67 % · 4,15 s/caso.
- Para este conjunto elegí BART por mejor accuracy observada y menor tiempo.
- La muestra es pequeña: no permite afirmar superioridad general ni desempeño de producción.

Métrica	BART	mDeBERTa multilingüe	Interpretación
Casos evaluados	12	12	Misma muestra
Aciertos	6	2	Predicciones correctas
Accuracy	50,00 %	16,67 %	Proporción de aciertos
Tiempo promedio	0,90 s/caso	4,15 s/caso	Tiempo observado

El score no es una garantía

Una predicción debe interpretarse como apoyo, no como verdad.

- Un ejemplo de prueba mostró que la categoría de mayor score podía no coincidir con la intuición humana.
- Los scores no son probabilidades calibradas de acierto.
- Próximos pasos: más casos, etiquetas revisadas, matriz de confusión, precision y recall por categoría.
- Los reportes ambiguos o multitema requieren revisión humana.

Los errores también fueron parte del aprendizaje

Separé errores de código de problemas de servicio y configuración.

- HF_TOKEN ausente y respuesta 401: revisar credenciales y permisos.
- Error 402: no había créditos remotos disponibles.
- La tarea text_classification no coincidía; se corrigió a zero_shot_classification.
- La ruta que quedó en la app usa el pipeline; el cliente remoto fue un experimento.

Un prototipo funcional, con límites explícitos

Publicado y preparado para seguir mejorando.

- Demo pública en Hugging Face Spaces.
- La IA generativa se utilizó como apoyo documental y técnico; el código y resultados se revisaron.
- La solución demuestra inferencia con un modelo preentrenado y despliegue de una interfaz.
- Conclusión: puede acelerar una primera lectura, pero necesita evaluación ampliada y supervisión humana.